



UNINASSAU

APRENDIZAGEM POR REFORÇO E BAYESIANA


Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

Tipos de Aprendizagem em ML



Aprendizagem por Reforço


O que é o Aprendizado por Reforço?



O que é o Aprendizado por Reforço?


O Aprendizado por Reforço (RL) é uma área interdisciplinar de Machine Learning que se concentra em como agentes inteligentes devem tomar ações em um ambiente para maximizar uma recompensa cumulativa.

- Diferente de outros paradigmas de ML: aprende por tentativa e erro
- Inspirado em psicologia comportamental: recompensas e punições
- Equilibra exploração (novas ações) e exploração (ações conhecidas)
- Aplicações: jogos, robótica, sistemas de recomendação, finanças, saúde



Componentes do Aprendizado por Reforço

- **Agente:** Entidade que toma decisões e executa ações no ambiente
- **Ambiente:** Mundo com o qual o agente interage e recebe feedback
- **Estado:** Representação da situação atual do ambiente
- **Ação:** Decisão tomada pelo agente que afeta o ambiente
- **Recompensa:** Feedback numérico que indica o sucesso da ação
- **Política:** Estratégia que mapeia estados para ações
- **Função de Valor:** Estima o benefício de longo prazo de estados e ações



Processos de Decisão de Markov (PDM)


Os Processos de Decisão de Markov (PDM)

fornece a estrutura matemática para modelar problemas de aprendizado por reforço.

- **S**: Conjunto de estados do ambiente
- **A**: Conjunto de ações possíveis
- **P(s' | s, a)**: Probabilidade de transição para o estado s' após executar a ação a no estado s
- **R(s, a, s')**: Recompensa recebida após transição
- **γ**: Fator de desconto ($0 \leq \gamma \leq 1$)


$$V(s) = \max_a [R(s, a) + \gamma * \sum_{s'} P(s' | s, a) * V(s')]$$

Markov decision process



Algoritmos sem Modelo

- Algoritmos que aprendem diretamente da experiência, sem construir um modelo explícito do ambiente.




Algoritmos sem Modelo

Q-Learning

Algoritmo off-policy que aprende o valor ótimo da ação independentemente da política seguida

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \cdot \max_{a'} Q(s',a') - Q(s,a)]$$



Q-Learning Algorithm



Algoritmos sem Modelo

SARSA

Algoritmo on-policy que aprende valores de ação para a política que está sendo seguida



Algoritmos sem Modelo

SARSA

Algoritmo on-policy que aprende valores de ação para a política que está sendo seguida


$$Q(s,a) = Q(s,a) + \alpha [r + \gamma Q(s',a') - Q(s,a)]$$

Updated Q-value Current Q-value Target Q-value Current Q-value

Algoritmos sem Modelo

Monte Carlo

Aprende diretamente a partir dos episódios de experiências adquiridas durante a interação com o ambiente, sem qualquer conhecimento prévio das transições do Processo de Decisão de Markov (MDP).




Aprendizado por Reforço Profundo

O **Aprendizado por Reforço Profundo** combina técnicas de aprendizado por reforço com redes neurais profundas para lidar com problemas complexos e espaços de estados de alta dimensão.

- **Representação de estados:** Redes neurais podem aprender representações eficientes de estados complexos (imagens, sons, etc.)
- **Aproximação de função:** Substitui tabelas Q por redes neurais para generalização
- **Escalabilidade:** Permite lidar com espaços de estados e ações muito grandes ou contínuos

Deep Q-Network (DQN)

Combina Q-learning com redes neurais profundas e utiliza técnicas como memória de replay e rede alvo para estabilizar o treinamento



Deep Q-Network (DQN)

Aplicações do Aprendizado por Reforço

- **Jogos:** Desenvolvimento de agentes que aprendem a jogar em níveis sobre-humanos

Ex: AlphaGo (Go), OpenAI Five (Dota 2), AlphaStar (StarCraft II)

- **Robótica:** Controle de robôs para tarefas complexas e adaptação a ambientes dinâmicos

Ex: Manipulação de objetos, locomoção, drones autônomos



Aplicações do Aprendizado por Reforço

- **Sistemas de Recomendação:**

Personalização de recomendações baseadas no feedback do usuário

Ex: Recomendação de produtos, conteúdo, anúncios

- **Finanças:** Otimização de portfólios e estratégias de trading automatizado

Ex: Alocação de ativos, execução de ordens

- **Saúde:** Tratamentos personalizados e otimização de protocolos médicos

Ex: Dosagem de medicamentos, planejamento de tratamentos



Desafios e Tendências Futuras

Desafios Atuais

- **Eficiência de amostra:**
Algoritmos atuais requerem muitas interações com o ambiente
- **Interpretabilidade:**
Modelos complexos são difíceis de entender e explicar
- **Generalização:** Dificuldade em transferir conhecimento entre tarefas



Desafios e Tendências Futuras

Tendências Futuras



- **Aprendizado por reforço multiagente:** Múltiplos agentes interagindo e aprendendo juntos
- **Aprendizado por reforço offline:** Aprender de dados pré-coletados sem interação direta
- **Aprendizado por reforço com feedback humano:** Incorporar orientação humana no processo



Aprendizagem Bayesiana

O que é aprendizagem Bayesiana?

- Antes de observar dados → temos uma crença inicial (prior)
- Após observar evidências → atualizamos essa crença (posterior)
- Ou seja: aprender = atualizar crenças probabilísticas com base em dados



“O aprendizado bayesiano consiste em usar dados para atualizar crenças prévias em crenças posteriores.”

— Kevin P. Murphy (2012), Machine Learning: A Probabilistic Perspective

Probabilidade Bayesiana

- Baseada no Teorema de Bayes:

$$P(A/B) = \frac{P(B/A) \times P(A)}{P(B)}$$

Onde:

- A: hipótese
- D: dados observados
- P(A): probabilidade a priori
- P(B/A): verossimilhança
- P(A/B): probabilidade a posteriori

Exemplo Simples (Médico)

Exemplo de teste para uma doença rara

Dados:

- Prevalência da doença: 1% = 0,01
- Sensibilidade do teste: 99% = 0,99
- Falsos positivos: 5% = 0,05

Se o teste deu positivo, qual a chance real de estar doente?


$$P(\text{Doença}|+) = \frac{0,99 \times 0,01}{(0,99 \times 0,01) + (0,05 \times 0,99)} \approx 16,7\%$$

mesmo com teste bom, a probabilidade real não é tão alta → importância da prevalência.

Aprendizagem Bayesiana

- Aprendizado = atualizar distribuições de probabilidade com base em novos dados
- Modelos bayesianos calculam **posteriores** a partir de **priors** + **dados**
- Difere do ML tradicional: considera **incerteza explicitamente**

Bayesian Networks




Vantagens e Limitações da Aprendizagem Bayesiana

Vantagens

- Trata naturalmente a incerteza
- Integra conhecimento prévio (priors)
- Funciona bem com **poucos dados**
- Fácil interpretação probabilística

Limitações

- Computacionalmente custoso em bases grandes
- Resultados sensíveis à escolha dos priors
- Se variáveis não forem independentes e o modelo assumir independência → erros



Algoritmo Clássico: Naive Bayes


Assume atributos independentes entre si

Fórmula:

$$P(C|X) \propto P(C) \prod_i P(x_i|C)$$

- Rápido, eficiente, simples
- Muito usado em classificação de textos e spam


Exemplo: Detecção de Spam




Se $P(\text{spam} \mid x) > P(\text{n\~ao spam} \mid x)$ $\rightarrow$ classifica como spam

Redes Bayesianas

- Modelos gráficos probabilísticos
- **Nós:** variáveis
- **Arestas:** dependências condicionais
- Representam sistemas complexos: saúde, redes sociais, previsão de falhas




Tipos de Problemas Resolvidos



Aplicações Práticas

- Diagnóstico médico
- Processamento de linguagem natural
- Reconhecimento de padrões
- Sistemas de recomendação
- Detecção de fraudes financeiras



EXEMPLOS

Ex01:Aproximação de MSE usando Monte Carlo

- A ideia é usar o Monte Carlo para aproximar **a integral do erro quadrático médio (MSE)** de uma função de regressão simples.

Erro Quadrático Médio - MSE

O erro quadrático médio, MSE (da sigla em inglês Mean Squared Error), é comumente usado para verificar a acurácia de modelos e dá um maior peso aos maiores erros, já que, ao ser calculado, cada erro é elevado ao quadrado individualmente e, após isso, a média desses erros quadráticos é calculada. Temos a equação abaixo:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Ex01: Aproximação de MSE usando Monte Carlo

- A ideia é usar o Monte Carlo para aproximar **a integral do erro quadrático médio (MSE)** de uma função de regressão simples.

Código no Google Colab

Explicação passo a passo


- **Geramos dados sintéticos:** uma relação linear $y = 2x + 3$ com ruído gaussiano.
- **Definimos um modelo de regressão:** aqui, uma linha aproximada $y = 2.1x + 2.9$.
- **Monte Carlo:** fazemos várias amostragens aleatórias com substituição (bootstrap) de nossos dados, calculando o MSE de cada amostra.
- **Estimativa final:** média e desvio padrão do MSE, aproximando o erro esperado do modelo.

Esse é um uso bem simples do Monte Carlo em Machine Learning, que pode ser expandido para otimização de hiperparâmetros, estimativa de incerteza de modelos ou integração de funções complexas.

Ex02: Detecção de Spam com Naive Bayes

- Vamos criar um exemplo simples de detecção de spam usando Aprendizagem Bayesiana (Naive Bayes)

```
# Criando um conjunto de dados simples
data = {
    'mensagem': [
        "Ganhe dinheiro rápido",
        "Oferta imperdível, clique aqui",
        "Olá, como você está?",
        "Reunião amanhã às 10h",
        "Seu empréstimo aprovado",
        "Vamos almoçar hoje?",
        "Parabéns, você ganhou um prêmio",
        "Relatório do projeto enviado",
        "Promoção válida só hoje",
        "Vamos jogar futebol no sábado"
    ],
    'spam': [1, 1, 0, 0, 1, 0, 1, 0, 1, 0] # 1 = spam, 0 = não spam
}
```



Ex01: Aproximação de MSE usando Monte Carlo

- Detecção de spam usando Aprendizagem Bayesiana (Naive Bayes)

Código no Google Colab

Explicação passo a passo

1. **Dados sintéticos:** Criamos um dataset simples de mensagens com label spam (1) ou não spam (0).
2. **Pré-processamento:** Usamos CountVectorizer para transformar texto em números (Bag of Words).
3. **Treinamento:** Modelo **Naive Bayes Multinomial**, ótimo para texto e classificação de spam.
4. **Avaliação:** Calculamos acurácia e mostramos matriz de confusão.
5. **Teste com novas mensagens:** O modelo classifica se novas mensagens são spam ou não.

Blade Runner 2049 (2017)



Em Blade Runner 2049, após os problemas enfrentados com os Nexus 8, uma nova espécie de replicantes é desenvolvida, de forma que seja mais obediente aos humanos. Um deles é K (Ryan Gosling), um blade runner que caça replicantes foragidos para a polícia de Los Angeles. Após encontrar Sapper Morton (Dave Bautista), K descobre um fascinante segredo: a replicante Rachel (Sean Young) teve um filho, mantido em sigilo até então. A possibilidade de que replicantes se reproduzam pode desencadear uma guerra deles com os humanos, o que faz com que a tenente Joshi (Robin Wright), chefe de K, o envie para encontrar e eliminar a criança.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679
3. FASTERCAPITAL. Otimização bayesiana: como usar inferência e aprendizagem bayesiana na otimização de portfolio. FasterCapital, 22 abril 2025. Disponível em: <https://fastercapital.com/pt/contente/Otimizacao-bayesiana--como-usar-inferencia-e-aprendizagem-bayesiana-na-otimizacao-de-portfolio.html>. Acesso em: 14 Set. 2025.
4. FASTERCAPITAL. Desmistificando o aprendizado por reforço profundo: um guia abrangente. FasterCapital, 12 maio 2025. Disponível em: <https://fastercapital.com/pt/contente/Desmistificando-o-aprendizado-por-reforco-profundo--um-guia-abrangente.html>. Acesso em: 14 Set. 2025.

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code